



Manual de Usuario

Mortality AMI Predictor

Sistema de Predicción de Mortalidad
en Infarto Agudo de Miocardio



Personal Clínico

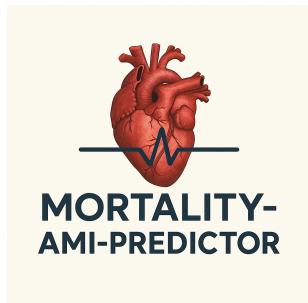


Científicos de Datos



Desarrolladores

Versión 2.0 | Diciembre 2025



Versión 1.0

Integrantes del Equipo:

- Richard Alejandro Matos Arderí
- Abel Ponce González
- Abraham Romero Imbert
- Michell Viu Ramirez
- Eveliz Espinaco Milián
- Eduardo Brito Labrada
- Ernesto Abreu Peraza

Institución:

Facultad de Matemática y Computación
Universidad de La Habana

Registro Cubano de Infarto Agudo del Miocardio

25 de diciembre de 2025

Índice

1. Introducción	4
1.1. Bienvenido a Mortality AMI Predictor	4
1.2. Perfiles de Usuario	4
2. Inicio Rápido	5
2.1. Requisitos del Sistema	5
2.2. Instalación	6
2.3. Primera Vista del Dashboard	6
3. Guía para Personal Clínico	6
3.1. Calculadora de Scores Clínicos	7
3.1.1. Score GRACE	7
3.1.2. Score TIMI	7
3.2. Realizar Predicciones	8
3.2.1. Predicción Individual	8
3.3. Entender las Predicciones (Explicabilidad Básica)	8
3.3.1. Gráfico de Importancia de Variables	9
3.3.2. Ejemplo de Interpretación	9
4. Guía para Científicos de Datos	9
4.1. Carga y Limpieza de Datos	9
4.1.1. Carga de Datos	9
4.1.2. Pipeline de Limpieza	10
4.2. Análisis Exploratorio de Datos (EDA)	10
4.2.1. Análisis Univariado	10
4.2.2. Análisis Bivariado	11
4.2.3. Análisis Multivariado	11
4.3. Entrenamiento de Modelos	11
4.3.1. Algoritmos Disponibles	11

4.3.2. Validación Cruzada Rígurosa	11
4.4. Evaluación de Modelos	12
4.4.1. Métricas de Clasificación	12
4.4.2. Curvas de Calibración	12
4.4.3. Decision Curve Analysis (DCA)	13
4.5. Explicabilidad Avanzada (SHAP)	13
4.5.1. Visualizaciones SHAP	13
4.5.2. Interpretación de SHAP	13
4.6. AutoML	13
4.6.1. Backends Disponibles	13
4.6.2. Presets de Búsqueda	14
4.7. Optimización Inversa	14
4.7.1. Concepto	14
4.7.2. Configuración	14
5. Guía para Desarrolladores	14
5.1. Modelos Personalizados	14
5.1.1. Arquitectura Base	15
5.1.2. Métodos Requeridos	15
5.1.3. Flujo de Trabajo	15
5.2. Despliegue con Docker	16
5.2.1. Construcción de la Imagen	16
5.2.2. Ejecución del Contenedor	16
5.2.3. Docker Compose	16
5.3. Estructura del Código	16
5.4. API Programática	17
6. Referencia de Páginas del Dashboard	18
7. Solución de Problemas	18
7.1. Problemas Comunes	18

7.2. Mensajes de Error Frecuentes	19
8. Glosario	19
9. Contacto y Soporte	20

1 Introducción

1.1 Bienvenido a Mortality AMI Predictor

Mortality AMI Predictor es una aplicación integral para la predicción de mortalidad intrahospitalaria en pacientes con Infarto Agudo de Miocardio (IAM). El sistema combina técnicas avanzadas de Machine Learning con una interfaz intuitiva diseñada para diferentes perfiles de usuario.

Propósito del Sistema

El objetivo principal es proporcionar herramientas que ayuden a:

- Predecir el riesgo de mortalidad intrahospitalaria
- Calcular scores clínicos validados (GRACE, TIMI)
- Analizar factores de riesgo mediante explicabilidad
- Optimizar intervenciones mediante análisis “what-if”

Uso Responsable

Esta herramienta es para **fines de investigación y educación**. Las decisiones clínicas deben ser tomadas siempre por profesionales de salud cualificados utilizando su juicio clínico.

1.2 Perfiles de Usuario

El sistema está diseñado para tres tipos principales de usuarios, cada uno con diferentes necesidades y niveles de experiencia técnica:

Personal Clínico

Médicos, enfermeros y personal sanitario que necesitan:

- Calcular scores de riesgo clínico rápidamente
- Obtener predicciones de mortalidad para pacientes
- Entender qué factores influyen en el pronóstico

Secciones recomendadas: Predicciones, Scores Clínicos, Explicabilidad básica

📊 Científicos de Datos / Investigadores

Analistas y estadísticos que requieren:

- Análisis exploratorio de datos clínicos
- Entrenamiento y comparación de modelos
- Evaluación rigurosa con métricas estándar
- Análisis de explicabilidad avanzado (SHAP)

Secciones recomendadas: Limpieza de Datos, EDA, Entrenamiento, Evaluación, AutoML

</> Desarrolladores / Programadores

Ingenieros de ML y desarrolladores que buscan:

- Crear modelos personalizados
- Integrar con sistemas externos
- Extender funcionalidades
- Desplegar en producción con Docker

Secciones recomendadas: Modelos Personalizados, API, Despliegue Docker

2 Inicio Rápido

2.1 Requisitos del Sistema

Componente	Requisito
Sistema Operativo	Windows 10/11, macOS 10.15+, Linux (Ubuntu 20.04+)
Python	3.9 o superior
RAM	Mínimo 8 GB (16 GB recomendado para AutoML)
Espacio en disco	2 GB para instalación + espacio para datasets
Navegador	Chrome, Firefox, Edge o Safari (versiones recientes)

Cuadro 1: Requisitos mínimos del sistema

2.2 Instalación

Paso 1: Clonar el repositorio o descargar los archivos del proyecto:

```
git clone https://github.com/tu-usuario/mortality-ami-predictor.git  
cd mortality-ami-predictor/Tools
```

Paso 2: Crear un entorno virtual e instalar dependencias:

```
python -m venv venv  
venv\Scripts\activate      # Windows  
source venv/bin/activate   # Linux/macOS  
pip install -r requirements.txt
```

Paso 3: Iniciar la aplicación:

```
streamlit run dashboard/Dashboard.py
```



La aplicación se abrirá automáticamente en tu navegador en <http://localhost:8501>

2.3 Primera Vista del Dashboard

Al iniciar la aplicación, verás la página principal con:

-  **Logo y título** del sistema
-  **Barra lateral** con navegación a todas las páginas
-  **Estadísticas rápidas** del dataset (si está configurado)
-  **Información** sobre las funcionalidades disponibles

3 Guía para Personal Clínico

Sección para Personal Clínico

Esta sección está diseñada para médicos y personal sanitario.

No requiere conocimientos de programación ni estadística avanzada.

3.1 Calculadora de Scores Clínicos

La página [6 Clinical Scores](#) permite calcular los scores de riesgo más utilizados en cardiología.

3.1.1 Score GRACE

El **GRACE Score** (Global Registry of Acute Coronary Events) estima la mortalidad intrahospitalaria y a 6 meses en pacientes con síndrome coronario agudo.

Para calcular el score GRACE:

1. Navega a [06 Clinical Scores](#)
2. Selecciona “GRACE Score” en el menú desplegable
3. Introduce los datos del paciente:

Variable	Unidad	Descripción
Edad	años	Edad del paciente
Frecuencia cardíaca	lpm	Latidos por minuto al ingreso
Presión arterial sistólica	mmHg	PA sistólica al ingreso
Creatinina	mg/dL	Nivel sérico de creatinina
Clase Killip	I-IV	Clasificación de insuficiencia cardíaca
Desviación ST	Sí/No	Elevación o depresión del ST en ECG
Enzimas cardíacas	Sí/No	Troponina o CK-MB elevadas
Parada cardíaca	Sí/No	PCR al ingreso

4. Haz clic en [Calcular GRACE Score](#)
5. Revisa el resultado con la categoría de riesgo

Interpretación del GRACE Score

- **Bajo riesgo:** < 109 puntos (mortalidad < 1 %)
- **Riesgo intermedio:** 109-140 puntos (mortalidad 1-3 %)
- **Alto riesgo:** > 140 puntos (mortalidad > 3 %)

3.1.2 Score TIMI

El **TIMI Score** evalúa el riesgo en pacientes con IAM con elevación del ST.

Variables del TIMI:

- Edad \geq 65 años

- Diabetes mellitus
- Hipertensión arterial
- Infarto previo
- Otros factores cardiovasculares

3.2 Realizar Predicciones

La página  **Predictions** permite obtener predicciones de mortalidad para pacientes individuales.

3.2.1 Predicción Individual

1. Navega a **03  Predictions**
2. Selecciona un modelo entrenado en la barra lateral
3. Introduce los valores de las variables clínicas del paciente
4. El sistema mostrará:
 - **Probabilidad de mortalidad** (0-100 %)
 - **Clasificación de riesgo** (bajo/medio/alto)
 - **Factores más influyentes** en la predicción

Interpretación Clínica

Las predicciones del modelo son **probabilísticas** y deben interpretarse en el contexto clínico completo del paciente. Considere siempre:

- Comorbilidades no incluidas en el modelo
- Factores socioeconómicos
- Preferencias del paciente
- Recursos disponibles

3.3 Entender las Predicciones (Explicabilidad Básica)

La página  **Explainability** ayuda a entender **por qué** el modelo hace una predicción.

3.3.1 Gráfico de Importancia de Variables

Este gráfico muestra qué variables tienen mayor influencia en la predicción:

- **Barras rojas:** Variables que **aumentan** el riesgo
- **Barras verdes:** Variables que **disminuyen** el riesgo
- **Longitud de la barra:** Magnitud del impacto

3.3.2 Ejemplo de Interpretación

Paciente ejemplo:

- Probabilidad de mortalidad: **35 %**
- Factor principal de riesgo: **Edad avanzada (+12 %)**
- Factor protector principal: **PA sistólica normal (-8 %)**

Interpretación: La edad del paciente es el factor que más contribuye al riesgo, mientras que una presión arterial sistólica dentro de rangos normales actúa como factor protector.

4 Guía para Científicos de Datos

📊 Sección para Científicos de Datos

Esta sección asume conocimientos de estadística, ML y análisis de datos.

4.1 Carga y Limpieza de Datos

La página  **Data Cleaning and EDA** es el punto de entrada para cualquier análisis.

4.1.1 Carga de Datos

El sistema soporta múltiples formatos y fuentes:

Método	Descripción	Formatos
Ruta del archivo	Especificar path absoluto o relativo	CSV, Excel
Subir archivo	Drag & drop o selección de archivo	CSV, XLSX, XLS
Dataset limpio	Cargar datasets previamente procesados	CSV

4.1.2 Pipeline de Limpieza

El módulo `DataCleaner` proporciona un pipeline configurable:

1. Imputación de valores faltantes

- Numéricos: media, mediana, KNN
- Categóricos: moda, valor constante

2. Detección y tratamiento de outliers

- Métodos: IQR, Z-score
- Tratamiento: cap (winsorización), remove, impute

3. Codificación de variables categóricas

- Label encoding
- One-hot encoding
- Target encoding

4. Escalado de características

- StandardScaler (z-score)
- MinMaxScaler
- RobustScaler

Tip: Configuración Recomendada

Para datos clínicos con outliers y valores faltantes:

- Imputación numérica: **mediana** (robusta a outliers)
- Outliers: **IQR + cap** (preserva datos)
- Escalado: **RobustScaler** (insensible a outliers)

4.2 Análisis Exploratorio de Datos (EDA)

4.2.1 Análisis Univariado

- **Variables numéricas:** Histogramas, boxplots, estadísticos descriptivos (μ, σ , mediana, IQR)
- **Variables categóricas:** Gráficos de barras, frecuencias absolutas y relativas

4.2.2 Análisis Bivariado

- **Numérico-Numérico:** Matriz de correlación (Pearson, Spearman), scatter plots
- **Numérico-Categórico:** Boxplots por grupo, pruebas t/Mann-Whitney
- **Categórico-Categórico:** Tablas de contingencia, Chi-cuadrado, Cramér's V

4.2.3 Análisis Multivariado

- **PCA:** Reducción de dimensionalidad lineal
- **ICA:** Análisis de componentes independientes
- **Clustering:** Detección de subgrupos

4.3 Entrenamiento de Modelos

La página  **Model Training** permite entrenar múltiples algoritmos.

4.3.1 Algoritmos Disponibles

Categoría	Algoritmo	Características
Lineales	Logistic Regression	Interpretable, baseline
	SGD Classifier	Escalable a big data
	SVC (lineal)	Margen máximo
Árboles	Decision Tree	Interpretable, propenso a overfit
	Random Forest	Ensemble, robusto
Gradient Boosting	XGBoost	Alto rendimiento, rápido
	LightGBM	Eficiente en memoria
	CatBoost	Maneja categóricas nativamente
Instancia	KNN	No paramétrico
Redes	MLP	Captura no-linealidades

Cuadro 2: Algoritmos de clasificación disponibles

4.3.2 Validación Cruzada Rigurosa

El sistema implementa un pipeline de experimentación academicamente riguroso:

FASE 1 - Train + Validation:

- Repeated Stratified K-Fold (≥ 30 runs)
- Estimación de μ (media) y σ (desviación estándar)

- Curvas de aprendizaje

FASE 2 - Test:

- Bootstrap resampling
- Jackknife (leave-one-out)
- Intervalos de confianza

FASE 3 - Comparación Estadística:

- Test de normalidad (Shapiro-Wilk)
- Paired t-test o Mann-Whitney U
- Corrección de comparaciones múltiples

4.4 Evaluación de Modelos

La página [Model Evaluation](#) proporciona métricas exhaustivas.

4.4.1 Métricas de Clasificación

Métrica	Descripción	Rango
AUROC	Área bajo curva ROC	[0, 1]
AUPRC	Área bajo curva Precision-Recall	[0, 1]
Accuracy	Proporción de aciertos	[0, 1]
Precision	VP / (VP + FP)	[0, 1]
Recall (Sensibilidad)	VP / (VP + FN)	[0, 1]
Specificity	VN / (VN + FP)	[0, 1]
F1-Score	Media armónica Precision-Recall	[0, 1]
Brier Score	Error cuadrático medio de probabilidades	[0, 1] (menor = mejor)

Cuadro 3: Métricas de evaluación disponibles

4.4.2 Curvas de Calibración

Las curvas de calibración evalúan si las probabilidades predichas corresponden con las frecuencias observadas:

- **Modelo bien calibrado:** Curva cercana a la diagonal
- **Sobreconfianza:** Curva por debajo de la diagonal
- **Subconfianza:** Curva por encima de la diagonal

4.4.3 Decision Curve Analysis (DCA)

El DCA evalúa la utilidad clínica comparando con estrategias extremas:

- **Treat All:** Tratar a todos los pacientes
- **Treat None:** No tratar a nadie
- **Modelo:** El beneficio neto del modelo

4.5 Explicabilidad Avanzada (SHAP)

La página [Q Explainability](#) implementa análisis SHAP completo.

4.5.1 Visualizaciones SHAP

1. **Beeswarm Plot:** Distribución de valores SHAP por feature
2. **Bar Plot:** Importancia media absoluta
3. **Waterfall Plot:** Contribución de cada feature para una predicción
4. **Force Plot:** Visualización interactiva de predicciones individuales

4.5.2 Interpretación de SHAP

- **SHAP value positivo:** Aumenta la probabilidad de la clase positiva
- **SHAP value negativo:** Disminuye la probabilidad
- **Magnitud:** Indica la fuerza del efecto

4.6 AutoML

La página [AutoML](#) automatiza la búsqueda de modelos.

4.6.1 Backends Disponibles

Backend	Plataforma	Características
FLAML	Cross-platform	Rápido, ligero, 12+ estimadores
Auto-sklearn	Linux/WSL	Meta-learning, ensemble automático
AutoKeras (NAS)	Cross-platform	Neural Architecture Search

4.6.2 Presets de Búsqueda

- **Quick** (5 min): Exploración rápida para prototipado
- **Balanced** (1 hora): Balance entre tiempo y rendimiento
- **High Performance** (4 horas): Búsqueda exhaustiva

4.7 Optimización Inversa

La página [◎ Inverse Optimization](#) permite análisis “what-if”.

4.7.1 Concepto

La optimización inversa responde preguntas como:

“¿Qué valores de presión arterial y medicación minimizarían el riesgo de mortalidad para este paciente?”

4.7.2 Configuración

1. **Variables fijas:** Características no modificables (edad, sexo)
2. **Variables modificables:** Parámetros que pueden optimizarse (PA, medicación)
3. **Restricciones:** Límites clínicamente plausibles
4. **Objetivo:** Probabilidad target de mortalidad

5 Guía para Desarrolladores

Sección para Desarrolladores

Esta sección requiere conocimientos de Python y desarrollo de software.

5.1 Modelos Personalizados

La página [🔧 Custom Models](#) permite crear arquitecturas propias.

5.1.1 Arquitectura Base

Todos los modelos personalizados deben heredar de las clases base:

```
from src.models.custom_base import BaseCustomClassifier

class MiModelo(BaseCustomClassifier):
    def __init__(self, param1=10, name="MiModelo"):
        super().__init__(name=name)
        self.param1 = param1

    def fit(self, X, y):
        self._validate_input(X, training=True)
        # ... lógica de entrenamiento ...
        self.is_fitted_ = True
        return self

    def predict(self, X):
        self._validate_input(X)
        # ... lógica de predicción ...
        return predictions

    def predict_proba(self, X):
        # ... probabilidades ...
        return probabilities
```

5.1.2 Métodos Requeridos

Método	Tipo	Descripción
__init__()	Obligatorio	Constructor con hiperparámetros
fit(X, y)	Obligatorio	Entrenar el modelo
predict(X)	Obligatorio	Predicciones de clase
predict_proba(X)	Clasificadores	Probabilidades por clase
get_params()	Recomendado	Obtener hiperparámetros
set_params()	Recomendado	Establecer hiperparámetros

5.1.3 Flujo de Trabajo

1. Crear el código Python del modelo
2. Guardarlo en `src/models/custom/`

3. Ir a [Model Training](#)

4. Activar “Include Custom Models” en la barra lateral
5. Seleccionar el modelo y entrenar

5.2 Despliegue con Docker

5.2.1 Construcción de la Imagen

```
cd Tools/docker
docker build -t mortality-ami-predictor ..
```

5.2.2 Ejecución del Contenedor

```
docker run -p 8501:8501 \
-v $(pwd)/DATA:/app/DATA:ro \
-v $(pwd)/models:/app/models \
mortality-ami-predictor
```

5.2.3 Docker Compose

Para entorno de desarrollo completo:

```
docker-compose --profile dev up -d
```

Esto levanta:

- **app** (puerto 8501): Dashboard Streamlit
- **jupyter** (puerto 8888): Jupyter Lab para desarrollo
- **mlflow** (puerto 5000): Tracking de experimentos

5.3 Estructura del Código

```
Tools/
+-- dashboard/
|   +-- Dashboard.py          # Entrada principal
|   +-- app/                   # Utilidades y estado
|   +-- pages/                # Páginas del dashboard
+-- src/
```

```
|   +-+ data_load/          # Carga de datos
|   +-+ cleaning/          # Limpieza
|   +-+ eda/               # Análisis exploratorio
|   +-+ features/          # Ingeniería de features
|   +-+ models/             # Definiciones de modelos
|   +-+ training/           # Pipeline de entrenamiento
|   +-+ evaluation/         # Métricas y evaluación
|   +-+ explainability/    # SHAP y explicabilidad
|   +-+ automl/             # AutoML integrations
|   +-+ scoring/            # Scores clínicos
+-+ tests/                 # Tests automatizados
+-+ docker/                # Configuración Docker
```

5.4 API Programática

Para integración con sistemas externos:

```
# Carga de datos
from src.data_load import load_dataset, train_test_split

# Limpieza
from src.cleaning import DataCleaner, CleaningConfig

# Entrenamiento
from src.training import run_rigorous_experiment_pipeline

# Predicción
from src.models import make_classifiers
model = make_classifiers()['xgboost']
model.fit(X_train, y_train)
predictions = model.predict_proba(X_test)

# Explicabilidad
from src.explainability import compute_shap_values
shap_values = compute_shap_values(model, X_test)
```

6 Referencia de Páginas del Dashboard

#	Página	Funcionalidad	●	●	●
00	Data Cleaning & EDA	Limpieza de datos y análisis exploratorio	✓	✓	
01	Data Overview	Resumen y estadísticas del dataset	✓		
02	Model Training	Entrenamiento con validación cruzada	✓	✓	
03	Predictions	Predicciones individuales y por lotes	✓	✓	
04	Model Evaluation	Métricas, ROC, calibración, DCA	✓		
05	Explainability	SHAP, permutación, PDP	✓	✓	
06	Clinical Scores	GRACE y TIMI	✓		
07	Custom Models	Creación de modelos personalizados		✓	
08	Inverse Optimization	Optimización de features	✓	✓	
09	AutoML	Entrenamiento automático	✓		

Cuadro 4: Páginas del dashboard y perfiles de usuario recomendados

Leyenda:  Personal Clínico |  Científicos de Datos |  Desarrolladores

7 Solución de Problemas

7.1 Problemas Comunes

Problema	Solución
“No hay datos cargados”	Ir a la página 00 y cargar un dataset primero
“No trained models found”	Entrenar modelos en la página 02 antes de usar predicciones
Error de codificación al cargar CSV	El sistema intenta múltiples encodings automáticamente. Si falla, convertir a UTF-8
SHAP tarda mucho	Reducir el número de muestras en la barra lateral
AutoML no disponible	Instalar FLAML: <code>pip install flaml[automl]</code>
Auto-sklearn no funciona	Solo disponible en Linux. Usar FLAML en Windows/macOS
Memoria insuficiente	Reducir tamaño del dataset o usar submuestreo

7.2 Mensajes de Error Frecuentes

⚠ Target column not found

Causa: El nombre de la columna objetivo no coincide con la configuración.

Solución: Verificar que el dataset contiene una columna llamada `mortality_inhospital` o configurar la variable de entorno `TARGET_COLUMN`.

⚠ Module not found: shap

Causa: La librería SHAP no está instalada.

Solución: Ejecutar `pip install shap` en el entorno virtual.

8 Glosario

AUROC Área Bajo la Curva ROC (Receiver Operating Characteristic). Mide la capacidad discriminativa del modelo.

AUPRC Área Bajo la Curva Precision-Recall. Útil para datasets desbalanceados.

AutoML Machine Learning Automatizado. Búsqueda automática de algoritmos e hiperparámetros.

Calibración

Grado en que las probabilidades predichas coinciden con las frecuencias observadas.

DCA Decision Curve Analysis. Evalúa la utilidad clínica de un modelo.

Feature Variable o característica utilizada como entrada del modelo.

FLAML Fast and Lightweight AutoML. Framework de AutoML de Microsoft.

GRACE Global Registry of Acute Coronary Events. Score clínico para SCA.

IAM Infarto Agudo de Miocardio.

ICA Independent Component Analysis. Técnica de reducción de dimensionalidad.

Killip Clasificación de insuficiencia cardíaca en IAM (I-IV).

NAS Neural Architecture Search. Búsqueda automática de arquitecturas de redes neuronales.

PCA Principal Component Analysis. Reducción de dimensionalidad lineal.

SHAP SHapley Additive exPlanations. Método de explicabilidad basado en teoría de juegos.

TIMI Thrombolysis In Myocardial Infarction. Score de riesgo cardiovascular.

9 Contacto y Soporte

❓ ¿Necesitas ayuda?

- 💡 <https://github.com/Pol4720/mortality-ami-predictor>
- 📘 Documentación técnica en [Tools/docs/](#)
- 🛠️ Reportar issues en GitHub
- 📞 +53 58258556

Mortality AMI Predictor v2.0
Desarrollado con ❤️ para la investigación médica
Diciembre 2025